

基于深度学习的金属加工表面缺陷自动化视觉检测系统

1 问题描述与应用场景

金属零件在机械领域有着非常重要、非常广泛的应用，很多机器对金属零件的精密密度有着较高的要求。然而在加工、运输、存储等过程中，零件表面难免会受到各种各样意想不到的伤害，这会损害零件表面的完整性，使金属表面产生划痕、斑块、裂纹等缺陷。这些缺陷会降低零件的使用寿命以及可靠性，甚至导致零件无法使用。为了防止有缺陷的零件造成损失，我们在改进制造工艺、降低缺陷率的同时，还需要行之有效的缺陷检测机制。

在计算机普及之前，金属表面的缺陷检测一般依赖于人工检测，也就是肉眼观察。这种检测方法有着很明显的缺点，一是存在极大的主观性，即便是同一个零件，同一个质检员，相隔一段时间进行两次检测也很难得到完全相同的结果，遑论不同质检员可能对检测标准有着个人的理解，这可能造成误判；二是视觉疲劳会使误判率急剧上升，人在长时间面对大量有着复杂纹理或很高反光的金属表面时，视觉的灵敏度会迅速下降，并且大量的重复会使大脑难以将注意力集中在缺陷检测上；三是效率低下，人工检测完全无法匹配机器的生产速度，会严重拖累生产。

这些问题在计算机普及后得到了一定的解决，因为人们开始使用计算机进行缺陷检验。然而在人工智能还未兴起的时间里，人们常用的是传统机器学习方法。尽管这种检测方法很好的避免了人工检验面对的问题，但它也存在灵活性不足、适应能力不足等问题。相比之下，新兴的深度学习方法不仅具有传统机器学习方法高效、客观、不知疲倦的优点，还能更好的适应工业生产的复杂环境。在设想中，这种基于深度学习的金属加工表面缺陷自动化视觉检测可以设置于生产流水线的末端，对每个产品都进行检测。相比于传统模式效率限制下的抽样检查，这种对零件表面缺陷的普查不仅仅能得出产品合格率，还能精确定位缺陷产品，从而将其剔除，提升零件的良品率。

2 图像获取与图像类型

由于研究条件限制，本项目使用开源数据集“东北大学钢材表面缺陷数据集（NEU-DET）”作为图像来源，并且为了提高效率，从 Roboflow Universe 平台获取已转换为 YOLO 架构所需 TXT 标注格式的数据源，共 1799 张图片，其中包含训练集 1439 张图片，测试集 144 张图片，验证集 216 张图片。

在工业生产条件下，可以有针对性的采集目标零件的图像数据。为了方便的采集金属表面图像，可以直接在零件生产流水线末端安装专业的工业用相机，自动采集相应零件的图像数据用于模型训练，这样可以兼顾训练数据的采集以及模型成形后的日常缺陷检测。

此外，该项目使用单色图像（灰度图）。因为金属加工表面缺陷以异常纹理、异常几何形状的形式出现，而与金属表面颜色没有太大关系。一般来说金属表面颜色并不会因出现缺陷而发生变化，因此颜色对于检测金属表面缺陷没有帮助，反而会引入无意义的干扰。将彩色图像转化为单色图像能够有效降低数据量、降低计算复杂度、压缩存储空间、提高计算效率，从而可以提高模型响应速度，来匹配工业生产对高效的要求，实现缺陷零件的实时分拣。最重要的是，这能简化模型特征维度，提高模型训练效率，降低该项目的实现难度。

3 神经网络模型的选择及其架构分析

随着深度神经网络的兴起与飞速发展，在图像识别领域有无数的模型可供选择，能否选出一个合适的深度神经网络模型直接关系到后面的任务能否完成。面对琳琅满目的模型，首先映入我眼帘的是诸如 ResNet 的图像分类模型，这主要是因为它们结构最简单，训练成本低，似乎更容易实现。然而考虑到我们的任务目标是识别金属零件表面缺陷，在工业生产中所用图像传感器的画面中一般包含多个零件，如果仅能判断图像中是否存在缺陷，将无法精准剔除带有缺陷的零件。总而言之，单纯的图像分类模型无法满足我们的需求。为了能够精准定位缺陷位置、判断缺陷类型，我选择使用目标检测类的模型。

目标检测模型主要分为两阶段检测与单阶段检测两种，它们各有各的好处与不足。其中以 Faster R-CNN 为代表的双阶段目标检测有着精度高、抗干扰能力强等优点，然而由于其结构复杂、计算量大、无法实时响应、训练成本高等问题，导致其既不适合条件有限的本项目，也不适合快节奏、需要实时响应的工业生产。相比之下，以工业主流 YOLO 系列为代表的单阶段目标检测结构简洁、推理速度快，并且训练简单，提供了更多轻量化的选择。

综合考虑，我选择了工业中广泛应用的 YOLOv8 作为本项目的深度神经网络。更具体点讲，在本地硬件与时间的双重限制下，我选择了该模型家族中最轻量化的 YOLOv8n(Nano)版本。该版本虽然牺牲了少量的精度，但是带来了巨大的性能减负，即使在工业生产中也能作为嵌入式设备的核心，发挥巨大价值。




图 1 YOLOv8n 模型结构图^[1]

输入模型的数据（尽管插入的结构图中输入的是彩色图像，但是本项目实际上使用单色图像）首先会经过骨干部分(Backbone)，经过卷积之后，其中的 c2f 模块将负责提取金属表面的像素明暗突变，初步区分出异常的纹理。提取完这些基础特征后，不同压缩程度的数据将会进入颈部网络(Neck)，这些不同尺度的特征经过多次上采样以及融合拼接，形成信息更丰富的数据，能够提升模型对不同大小的缺陷的综合识别能力，防止小型的缺陷在多次的压缩过程中丢失。特征数据最后进入头部网络(Head)，并流向两条独立的分支，其中左侧分支用于定位缺陷的位置，右侧分支用于判断缺陷的类型。头部网络的这种解耦设计既能提高模型精准度，又能提高模型的收敛速度。

4 困难及解决

4.1 虚拟环境配置

由于是第一次进行深度神经网络模型训练，我对如何开始毫无头绪，对模型训练的流程一窍不通。即使有 AI 的帮助，我仍然遇到了很多阻碍，其中首当其冲的就是虚拟环境的配置，相比于以前单纯写 python 项目时常用的 python 自带的虚拟环境工具 venv，AI 强烈要求我使用 conda。这是一个陌生的工具，我能做的只有按照 AI 的叙述照猫画虎的一步步操作，整体上讲 AI 给出的步骤并没有问题，遗憾的是建立的虚拟环境被存储到了 C 盘，PyTorch 等依赖的巨大体量对我的 C 盘空间极不健康，我不得不花费大量时间调整虚拟环境的存储位置。

总而言之，虚拟环境配置作为深度神经网络模型训练的重要前期准备，对于初次进行深度神经网络模型训练的我是一个不得不面对的困难。好在这个困难只有一次，相信有了这一次的经验以后，下一次进行相关项目时这将不再是困难。

4.2 微小缺陷漏检




图 2 首次训练（v1）后得到的归一化混淆矩阵

经过首次模型训练（v1），大部分指标表现良好，然而从归一化混淆矩阵中可以看出龟裂(crazing)的漏检率相当高,达到了 72%，氧化铁皮压入(rolled-in_scale)的漏检率也达到了 43%。为了解决漏检问题，我又调整参数进行了多次训练。最初（v2）我尝试提高输入分辨率，同时引入了 AdamW 优化器，期望能放大微小特征。糟糕的是龟裂的漏检率不降反增，从 0.72 提高到 0.77。这令我大失所望，选择改回最初的参数进行其他方面的尝试。但在说其他解决路线前，我要说明的是虽然 v2 的表现不好，但在后面我意识到训练轮数对结果的巨大影响后，我在某次训练（v7）中改回 v2 的参数，仅仅把训练轮数从 50 提高到了 100。这次训练的结果令人欣喜，龟裂的漏检率有了明显的降低，现在它降到了 0.63，这说明这种方法是有效果的。

不过在发现上述方法的有效前，我还做了其他的尝试。在 v3 中，我在 v1 的基础上增加了一些参数(copy_paste=0.2,mosaic=0.5,erasing=0.4)，它们能提高训练数据中缺陷的出现概率，丰富全局特征，提高模型抗干扰能力。这么做是有效果的，龟裂的漏检率降到了 0.60。在后面的 v4、v5、v6 中，我在 v3 的基础上分别尝试仅提高图像输入尺寸(v6)、仅提高训练轮数(v4)、同时提高训练轮数与图像输入尺寸(v5)。最终结果是仅提高训练轮数的 v4 在龟裂的漏检率上与 v3 没有显著差异；仅提高图像输入尺寸的 v6 龟裂漏检率高达 0.82，比 v1 还高；同时提高训练轮数与图像输入尺

寸的 v5 龟裂漏检率显著降低，数值为 0.52。这三次训练的结果对比让我意识到提高图像输入尺寸时最好同时提高训练轮数，这可能是由于提高图像输入尺寸后数据复杂度上升，训练轮数过低会导致模型欠拟合（正是这时的发现启发我进行了上一段中提到的 v7）。

总而言之，我得到了两条降低龟裂漏检率的途径。出于时间因素考量，我仅选择了相同训练轮数下成绩更好的 v5 来作为下一次训练的基准。这一次训练（v8）我在 v5 的基础上进一步提高训练轮数（从 100 提高到了 200），得出的结果令人喜悦，龟裂的漏检率降低到了 0.43。虽然这个数字仍然很大，但相比于 v1，这已经有了巨大的进步，证明了这条解决问题的路径的可行性。

5 模型结果综合分析与实测评估

经过多次的模型训练后，我们得到了多个训练结果，这一章我将以综合效果最好的 v8 为代表对训练出的模型进行综合分析与评估。

5.1 训练状态分析




图 3 v8 的全局训练日志与变化趋势

图 3 左侧六张图对应训练集与验证集的三项损失的变化趋势。可以看到训练集对应的三张图中拟合曲线的形状大致相同，损失都在先快后慢的下降，代表着模型在训练集中随着训练轮数提高犯错越来越少。然而验证集中的曲线就不那么赏心悦目了，边界框定位损失（box_loss）与边缘焦点损失（df_l_loss）都呈现出 U 形，尤其是边缘焦点损失格外明显。它们都在 100 轮左右达到最小值，并在后面的轮数中或快或慢的提高，出现过拟合的现象。不过这些微小的损失提高与龟裂识别准确率的提高相比是可以接受的。

图 3 右上角两张图对应模型的精确率与召回率，它们的稳步上升意味着模型误检率与漏检率的稳步下降。图 3 右下角的两张图体现着模型的综合能力，它们均在提升到一定数值后基本不再变化，从趋势上看即使再增加训练轮数也不会有明显的提升。它们最终稳定到的数值不算很高，但对于这个极轻量级的深度神经网络来说已经很可观了。

5.2 综合评估与阈值选择

机器不是越敏感越好，但也不能太过迟钝。为了避免检测机制走向极端，我们需要确定一个合适的阈值。




图 4 v8 的 Precision-Recall (PR) 曲线

图 4 显示了召回率（不漏报的能力）与精确率（不误报的能力）之间的关系，曲线越接近右上角说明模型综合能力越强。可以看出模型对划痕（scratches）的识别能力极强，mAP 达到了 0.944。然而，尽管该模型相比于最初的 v1 来说对龟裂的召回率已经有了不小的提高，其仍然是该模型的一个巨大弱点，mAP 仅有 0.418。不过总体来讲该模型对所有类别的平均精度仍有 0.742，已经迈过了及格线。




图 5 v8 的 F1 分数随置信度阈值变化曲线

图 5 是一张极具指导意义的图表，它显示了 F1 分数（精确率与召回率的调和平均数）随置信度阈值变化的趋势。根据这张图，我们可以找出 F1 分数最高时对应的置信度（0.367），这表明当我们将置信度阈值设为 0.367 时系统的综合得分最高。它直接指导我们找出那个最合适的敏感度。

5.3 混淆矩阵解析




图 6 v8 的归一化混淆矩阵

归一化混淆矩阵纵轴代表预测结果，横轴代表实际缺陷类型，矩阵对角线上的数值代表模型对这种缺陷的召回率。

从图中可以看出模型对划痕（scratches）的准确度最高，达到了 0.97，对麻点（pitted_surface）与斑块（patches）的准确度也极为可观。把目光放到那些准确度的

低谷，我们可以看到龟裂（**crazing**）是准确度最低的缺陷。尽管与其他缺陷相比，龟裂的准确度很低，但与之前的几个版本的模型相比，其召回率已从 v1 的 0.28 提高到了现在的 0.57，是原来的两倍不止。

最右边一列的数据代表在实际上没有缺陷时模型做出的判断，也就是误检，其主要集中在夹杂物（**inclusion**）与龟裂。这是模型灵敏度太高导致的，也是为了更好的找出微小缺陷不得不付出的代价。另外值得注意的是，右下角的矩形中没有数据，这不代表这一栏是 0，而是这一栏没有意义，无法计算。

5.4 实际预测图展示




图 7 val_batch1_labels.jpg




图 9 val_batch2_labels.jpg




图 8 val_batch1_pred.jpg




图 10 val_batch2_pred.jpg

6 总结与收获

本项目以 YOLOv8n 为基础，进行了一系列的模型训练，最终得到了一个勉强可用的金属表面缺陷图像识别模型。这个模型并不完美，甚至可以说十分简陋，不过我还是在这次大作业的经历中学到了很多，从对深度学习模型训练无从下手的小白到现在至少对深度学习模型训练的整体流程有了一定的了解。我对人工智能的认知不再局限于空泛的概念，而是更深的理解了其背后的原理，知道了它是如何产生又是以何种形式存在。这次实践也让我更深刻的意识到 AI 算法将如何与传统制造业相结合，如何为这个世界带来更大的价值。

参考文献

[1]熊恩杰,张荣芬,刘宇红,等.面向交通标志的 Ghost-YOLOv8 检测算法[J].计算机工程与应用,2023,59(20):200-207.